

Multi-Agent Systems

AICB-P2T3 · Ngày 20 · Chương 4 — Agent Nâng Cao

VinUniversity

VinUniversity · Phase 2 · Track 3 · Tuần 4

HÃY SUY NGHĨ...

“Khi một agent không đủ — Supervisor, Debate, Parallel patterns giải quyết bài toán như thế nào?”

Giữ câu hỏi này trong đầu khi học bài hôm nay

Nội dung bài học

1. Tại sao cần nhiều Agent?
2. 5 Agentic Workflow Patterns (Anthropic)
3. Supervisor Pattern — Orchestration
4. Debate Agents — Adversarial Collaboration
5. Parallel Execution & Shared State
6. Multi-Agent Frameworks
7. Demo & Thực hành

Tại sao cần nhiều Agent?

Taxonomy, failure modes, và nguyên tắc “Start simplest”

01

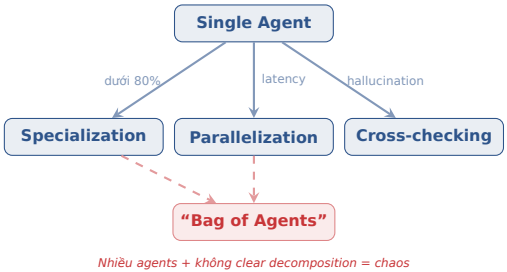
Multi-Agent = Team dự án

Multi-agent giống team dự án: có **PM** (supervisor), **specialists** (workers), **shared document** (state).

Single agent = 1 người làm hết: research, phân tích, viết báo cáo. Tốt cho task đơn giản.
Multi-agent = team 3 người: researcher tìm data, analyst phân tích, writer viết — mỗi người master 1 việc.

Nhưng: Team cũng có overhead — họp, miscommunication, conflict. **Chỉ scale khi 1 người không đủ.**

Multi-Agent Taxonomy — Khi nào cần nhiều Agent?



3 lý do chính để multi-agent:

1. **Specialization**: mỗi agent master 1 domain
2. **Parallelization**: concurrent subtasks, giảm latency
3. **Cross-checking**: consensus giảm hallucination

Lưu ý: Decision rule: nếu single agent đạt trên 80% accuracy thì **KHÔNG thêm agents** — complexity không justify.

Ví dụ thực tiễn — multi-agent giải quyết vấn đề gì?

Use case	Cấu trúc agent	Điểm học viên cần nhớ
Customer support triage	Triage agent route sang Billing / Refund / FAQ agent. Reference: OpenAI Agents SDK handoffs, `https://developers.openai.com/api/docs/guides/agents/orchestration`	Đây là routing pattern dễ hiểu nhất: mỗi intent có specialist riêng; sai route thì user nhận câu trả lời sai.
Code review assistant	Planner chia task, Code agent sửa, Test agent chạy test, Reviewer agent critique. Reference: GitHub Agent HQ / coding agents discussion, `https://github.blog/`	Multi-agent hữu ích khi cần plan–implement–verify, nhưng phải có test/CI làm ground truth.
Research report	Searcher thu thập nguồn, Analyst trích insight, Writer viết, Critic fact-check. Reference: Anthropic workflows, `https://www.anthropic.com/engineering/building-effective-agents`	Phù hợp lab hôm nay vì dễ so sánh single vs multi-agent theo quality, latency, cost.
Enterprise workflow	ADK agent teams phối hợp với tools và observability. Reference: Google ADK, `https://adk.dev/`	Production không chỉ là prompt: cần deploy, evaluate, trace, auth, guardrails.
Role-based automation	CrewAI crews: role, goal, tools, task. Reference: `https://crewai.com/`	Tốt để prototype nhanh khi muốn học viên thấy “agent như một vai trò trong team”.
Conversational col	AutoGen group chat / agent	Dùng để minh họa debate

Hoạt động 1 — Single agent hay multi-agent?

Nhiệm vụ nhóm (8 phút):

1. Với mỗi task, chọn: **single agent**, **workflow**, hay **multi-agent**.
2. Giải thích bottleneck chính: accuracy, latency, cost, hay ownership.
3. Nêu ít nhất 1 lỗi mới nếu dùng nhiều agent.

Task: FAQ đơn giản; research report; refund workflow; code migration.

"Nếu dùng nhiều agent, lỗi mới nào xuất hiện? Nếu dùng một agent, lỗi nào khó kiểm soát?"

Lưu ý: Mục tiêu không phải chọn multi-agent càng nhiều càng tốt; mục tiêu là biết **khi nào không nên dùng**.

14
Failure modes identified

3
Nhóm lỗi: spec, alignment, verification

150+
Tasks được phân tích

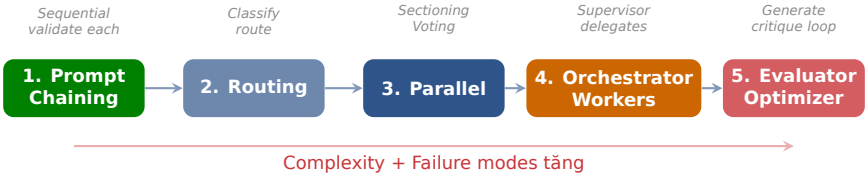
> “Why Do Multi-Agent LLM Systems Fail?” (arXiv:2503.13657) chỉ ra nhiều lỗi đến từ **specification / system design**, **inter-agent misalignment**, và **verification / termination**. Vì vậy cần define roles, stop condition, và rubric trước khi code.

5 Agentic Workflow Patterns (Anthropic)

Từ đơn giản đến phức tạp — escalate dần

02

5 Patterns — Escalation Ladder



"Start simplest. Only add agents when **measurably** needed." Thử Prompt Chaining trước. Chỉ escalate khi có bằng chứng cần.

Sectioning: split tasks → parallel workers
Voting: same task → multiple LLMs → aggregate

Hoạt động 2 — Pattern Card Sorting

Chia nhóm 3 người, mỗi nhóm nhận 1 case:

- Tổng hợp review khách hàng từ 1.000 comment
- Xử lý ticket refund / billing / technical support
- Viết báo cáo thị trường có fact-check nguồn
- Migrate codebase và đảm bảo test pass

Nhiệm vụ: chọn 1 trong 5 patterns, vẽ flow trong 4 phút.

Mỗi nhóm nói 30 giây: pattern, lý do, metric đo thành công, failure guard.

Lưu ý: Không được mặc định "supervisor cho mọi thứ". Hãy chứng minh pattern đơn giản hơn chưa đủ.

Routing Pattern — Cost Optimization

Routing — Classify input rồi chuyển đến specialized handler. Easy queries dùng small model, hard queries dùng large model.

- 70% queries easy = small model (GPT-4o-mini)
- 30% queries hard = large model (GPT-4o)
- Giảm 50%+ chi phí tổng thể

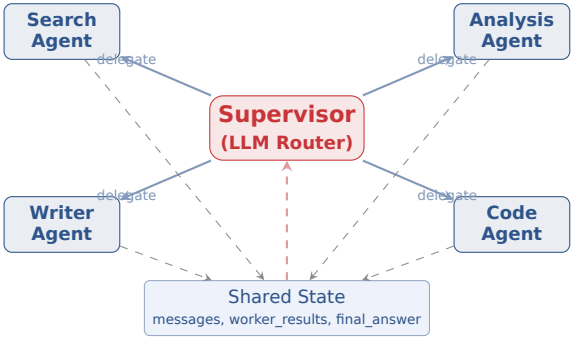
Khi workload có **bimodal difficulty** — nhiều query đơn giản + ít query phức tạp.

Lưu ý: Routing chỉ hiệu quả khi phân loại chính xác. Sai phân loại = query hard gửi cho small model = kết quả kém.

Supervisor Pattern — Orchestration

Hub-spoke delegation với LangGraph

Supervisor Pattern — Hub-Spoke Architecture



Supervisor — LLM router: nhận task, decompose, route đến workers, aggregate results

- Mỗi worker là node riêng với own tools
- Supervisor quyết định: gọi ai, theo thứ tự nào
- **Cost insight**: cheap model cho routing, expensive model cho workers

Supervisor State — LangGraph Implementation

```python
class SupervisorState(TypedDict):
    messages: list[BaseMessage]
    next_worker: str
    worker_results: dict[str, str]
    final_answer: str

# Supervisor routing via tool calls
def supervisor(state):
    response = llm.invoke(
      system="Route task to workers",
      tools=[search, analyze, write],
      messages=state["messages"]
    )
    return {"next_worker": response.tool}

# Build graph
graph = StateGraph(SupervisorState)
graph.add_node("supervisor", supervisor)
graph.add_node("search", search_agent)
graph.add_node("analyze", analysis_agent)
```

State gồm 4 thành phần:

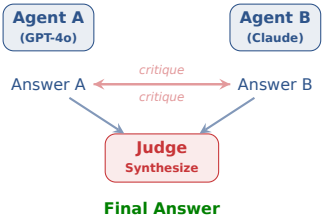
1. `messages`: conversation context
2. `next_worker`: ai được gọi tiếp
3. `worker_results`: output từ mỗi worker
4. `final_answer`: kết quả tổng hợp

Lưu ý: Failure modes: **#1** infinite routing loop (A → B → A). **#2** wrong worker selection. Cần **max iterations** guard.

Debate Agents — Adversarial Collaboration

Giảm hallucination qua tranh luận có kiểm soát

Debate Pattern — Adversarial Collaboration



Flow:

1. Agent A & B answer **independently**
2. Critique nhau (adversarial)
3. Judge synthesize final answer

> Debate giảm hallucination **15–25%**. Hiệu quả nhất cho ambiguous queries, high-stakes decisions.

Lưu ý: "Collective delusion": cả hai đồng ý sai → Judge không catch. Fix: dùng **diverse models**.

Society of Mind — Heterogeneous Agents

Agent	Model	Strength
Researcher	GPT-4o	Broad knowledge
Analyst	Claude	Nuanced reasoning
Critic	Gemini	Different training data
Judge	Best-of	Final synthesis

Mỗi model có **blind spots khác nhau** do training data diversity.

GPT-4 + Claude + Gemini $\rightarrow$ better coverage hơn 3 instances GPT-4.

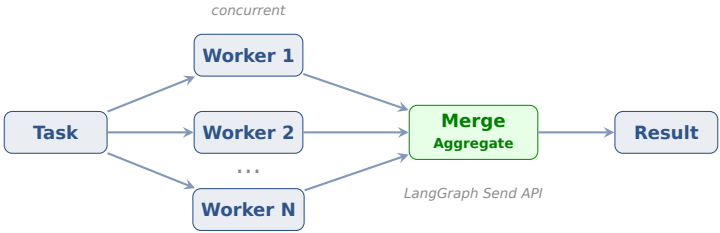
Trade-off: thêm latency (sequential critique) + cost (3 models). Chỉ justify cho high-stakes.

Parallel Execution & Shared State

Map-reduce, AsyncIO, và coordination patterns

05

Parallel Agent Execution — Map-Reduce



Dynamic fan-out + parallel branches — built-in parallelism. Mỗi worker chạy concurrent, merge khi tất cả done.

Lưu ý: "Parallel $\neq$ always faster": DAG dependencies, shared state locks, merge conflicts có thể negate speedup. Đo trước khi assume.

Shared State — Coordination Architecture

Shared state (blackboard) — Agents read/write central state — simple, cần locks cho concurrent writes. LangGraph dùng `TypedDict` state mặc định.

Message passing — Async queue (Redis Pub/Sub, Kafka) — decoupled, scalable, thêm network latency. Tốt cho distributed systems.

Lưu ý: Context loss across hand-offs: biggest coordination failure. Mỗi agent nhận partial context, quality giảm.

Multi-agent without tracing = impossible to debug. Dùng LangSmith hoặc Langfuse cho mọi multi-agent system.

Failure handling: supervisor detect timeout thì retry different worker hoặc fallback.

AsyncIO và Agent Pools — Production Concurrency

True concurrent execution cho multiple agents.

`asyncio.gather(agent1(), agent2())`

→ Parallel API calls, shared event loop

Pre-initialize N instances, use queue

→ Amortize init cost, control concurrency

Giống thread pool nhưng cho LLM agents

Production failure handling:

- Supervisor detect **timeout** → retry hoặc fallback
- **Circuit breaker**: fail 3 lần → skip, log, backup
- **Dead letter queue**: failed tasks lưu lại để debug

Lưu ý: Pool size = concurrent API rate limit. Quá nhiều agents → rate limit errors.

Multi-Agent Frameworks

LangGraph, AutoGen, CrewAI — chọn đúng công cụ

Framework Comparison — Chọn theo use case

Framework	Flexibility	Setup	Best for	Ghi chú
LangGraph	Cao	Trung bình	Production	State machines, full control
CrewAI	Trung bình	Dễ	Prototype	Role-based, nhanh onboard
AutoGen	Cao	Trung bình	Code exec	GroupChat, human-in-loop
OpenAI SDK	Thấp	Rất dễ	Simple	Lightweight, tool-use focused
Google ADK	Trung bình	Trung bình	GCP	Vertex AI, A2A protocol

AutoGen/CrewAI tốt cho prototype nhanh. **LangGraph cho production** — full state control, debugging, conditional routing. Migrate khi cần scale.

Demo & Thực hành

07

Multi-Agent Research System + 2 giờ lab có peer review

Predict-before-demo — học viên đoán trace trước

Cho học viên xem task: “Research GraphRAG state-of-the-art, write 500-word summary”. Hỏi: agent nào nên chạy trước? bước nào có thể parallel?

So sánh dự đoán với LangSmith trace: route có đúng không? worker nào tốn token nhất? lỗi nào cần guardrail?

Biến demo từ “giảng viên biểu diễn” thành “học viên debug một hệ thống thật”.

Multi-Agent Research System — Live Demo

1. Pipeline: Supervisor + SearchAgent + AnalysisAgent + WriterAgent
2. Task: “Research GraphRAG state-of-the-art, write 500-word summary” — supervisor coordinates
3. LangSmith trace: routing decisions, parallel timeline, worker outputs, final synthesis
4. So sánh: single-agent vs multi-agent trên cùng task — quality, latency, cost

Lab #20

Mục tiêu: Build 3-agent research system: Researcher + Analyst + Writer với LangGraph

Deliverable: Benchmark report: single-agent vs multi-agent (accuracy, latency, cost) + LangSmith traces

Thời gian: 2 giờ

Lab 20 — 2 giờ thực hành theo milestone

1. **0–15’** Setup: clone starter, set API key, chạy single-agent baseline.
2. **15–45’** Build supervisor: LangGraph state machine, routing via tool calls.
3. **45–75’** Add 3 workers: SearchAgent, AnalysisAgent, WriterAgent; lưu output vào shared state.
4. **75–95’** Trace & benchmark: single vs multi trên 3–5 research queries; đo quality, latency, cost.
5. **95–115’** Peer review: đổi nhóm, đọc trace của nhau, tìm 1 failure mode và đề xuất fix.
6. **115–120’** Exit ticket: mỗi nhóm ghi 1 điều nên dùng multi-agent và 1 điều không nên dùng.

GitHub repo + benchmark report + 1 LangSmith/Langfuse trace screenshot.
Bonus: thêm Critic Agent để fact-check.

Tiêu chí	Câu hỏi peer reviewer phải trả lời	Điểm
Role clarity	Mỗi agent có nhiệm vụ rõ, không overlap quá nhiều không?	0–2
State design	Shared state có đủ thông tin để handoff mà không mất context không?	0–2
Failure guard	Có max iterations, timeout, retry/fallback, hoặc validation không?	0–2
Benchmark	Có so sánh single vs multi-agent bằng metric cụ thể không?	0–2
Trace explanation	Nhóm giải thích được trace: ai làm gì, tốn bao nhiêu, sai ở đâu không?	0–2

> Mỗi nhóm review 1 nhóm khác trong 8 phút, sau đó owner có 5 phút sửa nhanh.

QUIZ Chương 4 + MILESTONE 1

10 câu trắc nghiệm + short answer:

Scope: Reflexion, Memory Systems, Production RAG, GraphRAG, Multi-Agent

Format: 7 MC + 3 short answer

Câu hỏi test understanding, không test nhớ syntax

Submit portfolio từ N16–N20:

- Lab 16: Reflexion agent
- Lab 17: Memory system
- Lab 18: Production RAG
- Lab 19: GraphRAG
- Lab 20: Multi-agent system

Deadline: 1 tuần sau N20

Reference links cho học viên tự đọc thêm

Anthropic: Building effective agents
`anthropic.com/engineering/building-effecti`

OpenAI: Agents SDK orchestration + handoffs
`developers.openai.com/.../orchestration`

AutoGen:
`microsoft.github.io/autogen`
CrewAI: `crewai.com`
Google ADK: `adk.dev`

LangGraph supervisor library
`reference.langchain.com/python/langgraph-s`

MAST paper: Why Do Multi-Agent LLM Systems Fail?
`arxiv.org/abs/2503.13657`

Lưu ý: Gợi ý đọc: học viên chỉ cần đọc Anthropic + OpenAI handoffs trước lab; các link còn lại dùng khi chọn framework cho project.

Tổng kết — Key Takeaways

Những ý chính cần nhớ trước khi sang bài tiếp theo

1. Supervisor là most practical multi-agent architecture — clear ownership, easy debug, production-ready
2. Debate giảm hallucination 15–25% nhưng tốn 2–3× cost — chỉ dùng cho high-stakes decisions
3. Parallel execution cắt latency nhưng cần careful state merge strategy — “parallel ≠ always faster”
4. Buổi học giữ lý thuyết trong 2 giờ; 2 giờ còn lại build, trace, benchmark, peer review

Tiếp theo & Bài tập

Ngày 21: Fine-tuning LLMs — LoRA/QLoRA

"Khi nào nên fine-tune — và khi nào prompt engineering đủ rồi?"

- Hoàn thành Lab 20 + submit Milestone 1 portfolio
- Đọc: MAST paper (NeurIPS 2025) — multi-agent failure taxonomy

Hỏi & Đáp

Supervisor vs Debate vs Parallel — khi nào dùng pattern nào? Single agent có khi nào đủ?



Cảm ơn!

AICB-P2T3 · Ngày 20 · Multi-Agent Systems

github.com/vinuni-aicb

Liên hệ: instructor@vinuni.edu.vn