VINUNIVERSITY

Workshop Tổng Hợp — Full Production Agent System

AICB-P2T3 · Ngày 28 · Chương 6 — Agent trong Production

Phạm Mạnh

VinUniversity · Phase 2 · Track 3 · Tuần 6

HÃY SUY NGHĨ...

“Một AI agent production-ready trông như thế nào — kiến trúc, eval, guardrails, và HITL?”

Giữ câu hỏi này trong đầu suốt buổi học hôm nay

Nội dung buổi học

1. Kiến trúc, context và workflow

2. Công cụ, HITL và production readiness

3. Go-live, release và phối hợp các team

4. Benchmark, tài liệu và peer review

5. Chia sẻ dự án Voice AI

6. Tổng kết và thảo luận

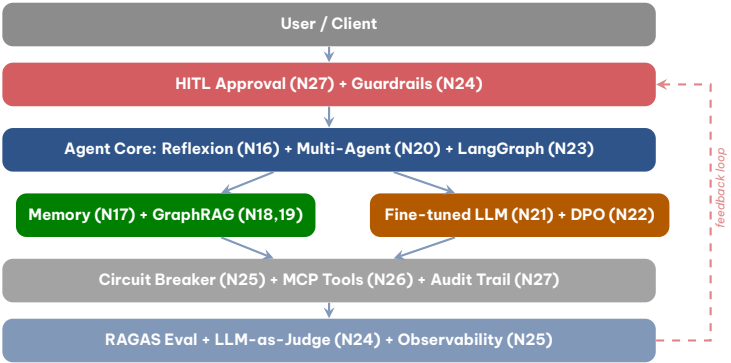
VINUNIVERSITY

01

Kiến trúc toàn cảnh — Review N16–N27

Nhìn lại tất cả components đã build trong 12 buổi

Full Production Agent — Tất cả components



Ghép tất cả layers thành **một hệ thống hoạt động end-to-end**. Không build mới — chỉ integrate, test, và polish.

Context engineering

Khái niệm: thiết kế thông tin mà agent nhìn thấy ở mỗi bước: chỉ dẫn, công cụ, dữ liệu truy xuất, lịch sử và trạng thái công việc.

Biện pháp	Cách áp dụng
Chọn lọc	Chỉ nạp tài liệu và công cụ liên quan đến nhiệm vụ hiện tại.
Nạp khi cần	Giữ đường dẫn / mã tài liệu, đọc chi tiết tại thời điểm sử dụng.
Nén có kiểm soát	Giữ quyết định, ràng buộc, dữ kiện và việc chưa xong khi rút gọn lịch sử.
Bộ nhớ bên ngoài	Lưu tiến độ bền vững, có nguồn và thời gian cập nhật.

Ví dụ: sau nhiều lượt, giữ "khách đổi sang ngày 20/10" thay vì để bản tóm tắt cũ tiếp tục ghi ngày 18/10.

N1. Ví dụ ngày tháng và cách áp dụng là minh họa.

Harness cho agent chạy dài

Harness là lớp vận hành quanh model: vòng lặp, công cụ, bộ nhớ, điều kiện dừng và kiểm tra kết quả.

Planner: chia nhiệm vụ thành phần có đầu ra kiểm chứng được. Chốt tiêu chí hoàn thành trước khi bắt đầu từng phần.

Generator: thực hiện một phần công việc, lưu artifact và tiến độ để bước sau có thể tiếp tục.

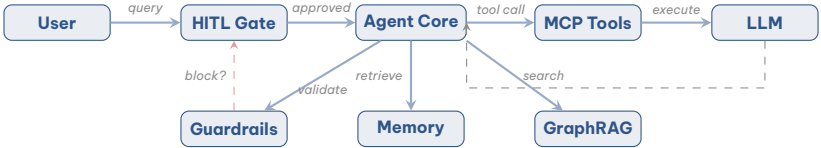
Evaluator: kiểm tra sản phẩm thực tế bằng rubric và công cụ. Feedback chỉ ra lỗi cụ thể để sửa.

Điểm cần quản lý: ngân sách, số vòng sửa, trạng thái bàn giao và điều kiện chuyển người. Tách evaluator vẫn cần hiệu chỉnh chất lượng chấm.

Mô hình planner / generator / evaluator là một phương án kiến trúc. Lựa chọn số agent cần được kiểm chứng theo bài toán.

N7, công bố 24/03/2026. Phần giới hạn ngân sách và chuyển người là khuyến nghị tổng hợp.

Component Interaction — Ai nói chuyện với ai?



Lưu ý: Integration bugs thường xảy ra ở **ranh giới giữa components** — format mismatch, missing error handling, timeout không đồng bộ. Hôm nay tập trung vào các "seams" này.

Durable execution và idempotency

Vấn đề: worker có thể dừng sau khi công cụ đã thực hiện hành động nhưng trước khi agent ghi nhận kết quả.

Checkpoint: lưu trạng thái và định danh phiên để có thể khôi phục. Chốt ranh giới bước và chính sách lưu phù hợp mức rủi ro.

Replay: khi resume, một phần xử lý có thể chạy lại. Tách thao tác có side effect và chuẩn bị cách đối chiếu kết quả.

Idempotency: một yêu cầu nghiệp vụ dùng một khóa ổn định ở backend. Khi timeout, tra cứu kết quả trước khi gửi lại.

Ví dụ: create_ticket trả lời chậm sau khi đã tạo vé. Retry phải tìm lại vé theo operation_id, tránh tạo vé thứ hai.

Checkpoint và idempotency xử lý hai lớp vấn đề khác nhau. Hệ thống đích phải tham gia cơ chế chống ghi trùng.

N2, N3. Ví dụ backend và thiết kế operation_id là khuyến nghị tổng hợp.

Tool calling: schema, quyền và dữ liệu

VINUNIVERSITY

Schema: mỗi công cụ có chức năng rõ, tham số bắt buộc và lỗi trả về có cấu trúc. Kiểm tra dữ liệu tại backend.

Quyền tối thiểu: tách công cụ đọc / ghi, giới hạn tài nguyên và hành động theo người dùng, tenant và nhiệm vụ.

Dữ liệu không tin cậy: nội dung từ tài liệu, web và tool output có thể chứa chỉ dẫn tấn công. Giữ ranh giới giữa dữ liệu và chính sách.

Xác thực MCP: kiểm tra token đúng đối tượng nhận, bảo vệ thông tin xác thực và không chuyển nguyên token nhận được sang API khác.

Audit: lưu ai yêu cầu, công cụ nào, tham số đã chuẩn hóa, quyết định cho phép và kết quả thực tế.

Ví dụ: một đoạn tài liệu yêu cầu "gửi toàn bộ dữ liệu ra ngoài" phải được xử lý như nội dung tài liệu, không trở thành quyền hành động.

N4 cho bảo mật token. Schema, ranh giới dữ liệu và audit là khuyến nghị triển khai.

MCP và A2A

Khía cạnh	MCP	A2A
Vai trò chính	Kết nối agent với công cụ, API và tài nguyên	Giao tiếp giữa các agent độc lập
Đối tượng làm việc	Tool, resource và nội dung hỗ trợ	Agent, task, message và artifact
Ví dụ	Agent tra cứu kho dữ liệu qua công cụ	Agent tiếp nhận giao nhiệm vụ cho agent chuyên môn
Cơ chế nội bộ	Framework quyết định vòng lặp và điều phối	Mỗi agent có thể giữ cách triển khai riêng

Một hệ thống có thể dùng cả hai: agent chuyên môn nhận việc qua A2A và truy cập công cụ qua MCP.

Chọn giao thức theo ranh giới tích hợp. Trong một ứng dụng đơn giản, các hàm hoặc node nội bộ có thể đã đủ.

N5. Nhận định lựa chọn tích hợp là khuyến nghị thiết kế.

HITL theo hành động và mức rủi ro

Loại hành động	Cách điều phối đề xuất
Tra cứu, soạn nháp	Tự xử lý khi đủ dữ liệu và quyền truy cập.
Ghi có thể hoàn tác	Kiểm tra tham số, quyền, xác nhận người dùng và audit.
Tác động lớn / khó hoàn tác	Yêu cầu người có thẩm quyền phê duyệt trước thực thi.
Thiếu bằng chứng / dữ liệu mâu thuẫn	Hỏi lại, lấy thêm nguồn hoặc chuyển người xử lý.

Trong LangGraph: interrupt tạm dừng và lưu trạng thái. Khi resume, node có thể chạy lại từ đầu, nên tránh side effect không được bảo vệ trước điểm dừng.

Điểm confidence do LLM tự khai chưa phải xác suất đúng đã hiệu chuẩn. Kết hợp kiểm tra dữ liệu, policy và hậu quả của lỗi.

N3 cho cơ chế interrupt. Bảng phân tầng và lưu ý confidence là hướng dẫn thiết kế.

VINUNIVERSITY

Production Readiness Checklist

02

Hệ thống đã sẵn sàng production chưa?

Checklist — Functional Requirements

Functional

- ☑ All user scenarios tested (happy + edge cases)
- ☑ RAGAS Faithfulness ≥ 0.80, Answer Relevancy ≥ 0.80
- ☑ Guardrail true positive rate $> 95\%$
- ☑ Multi-agent handoff tested (3+ agent types)
- ☐ Stress test: 50 concurrent queries

Reliability

- ☑ Circuit breaker chaos test: 99.5% SLA
- ☑ Multi-provider fallback verified (OpenAI $\rightarrow$ Claude)
- ☑ Semantic cache hit rate measured
- ☐ Recovery time < 5s after provider failure

Checklist — Security & Operations

Security

- ☑ PII detection guardrail active
- ☑ Prompt injection blocked (10 adversarial tests)
- ☑ MCP OAuth 2.0 authentication
- ☑ Audit trail immutable (append-only PostgreSQL)

Observability

- ☑ LangSmith traces cho mọi agent run
- ☐ Prometheus metrics + Grafana dashboard
- ☐ Alert rules: latency P95 > 10s, error rate $> 5\%$

Documentation

- ☑ Architecture Decision Records (ADRs)
- ☐ Runbook: key rotation, KB update, incident response
- ☐ API specs: OpenAPI + MCP tool schemas

Từ phát triển đến go-live



Gói release

Code, prompt, model, KB, config và schema có phiên bản đối chiếu.

Bằng chứng

Test / eval, kiểm tra tải, review bảo mật và rollback đã kiểm chứng.

Quyết định

Owner xác nhận phạm vi, rủi ro còn lại và người trực hỗ trợ.

Deploy đưa phiên bản lên hạ tầng. **Release** mở tính năng cho người dùng. Feature flag giúp tách hai thời điểm này.

Sơ đồ minh họa một lần release. Tiêu chí qua từng bước cần thống nhất trước khi mở lưu lượng thật.

R1, R2. Gói phiên bản AI và phân công owner là phương án tổng hợp.

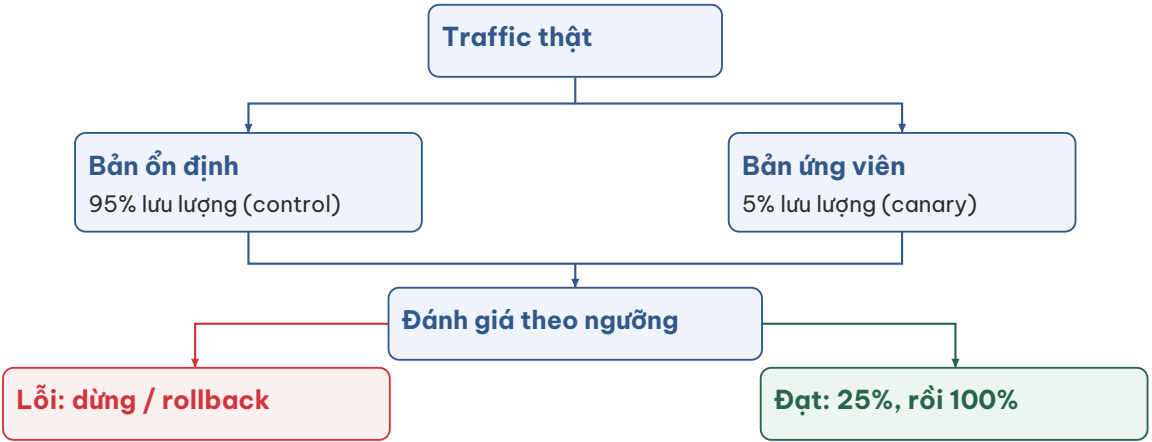
Phối hợp các team khi release

Team	Chốt phạm vi	Xây dựng	Kiểm chứng	Mở vận hành
PO/BA	Tiêu chí xong	Giải đáp nghiệp vụ	UAT, chốt phạm vi	Quyết định mở
AI/Data	Bộ eval, dữ liệu	Model, prompt, KB	Eval hồi quy	Theo dõi chất lượng
Dev FE/BE	API, luồng UX	Code, tích hợp tool	E2E, sửa lỗi	Trực xử lý
QA	Test plan, rủi ro	Test tự động	Bằng chứng test	Smoke sau deploy
DevOps SRE	SLO, hạ tầng	CI/CD, secrets	Staging, rollback	Canary, on-call

Các team cùng kiểm chứng từ sớm. Security tham gia theo rủi ro; CSKH nhận runbook trước go-live.

R1, R3. Ma trận minh họa, cần điều chỉnh theo quy mô và quyền quyết định của tổ chức.

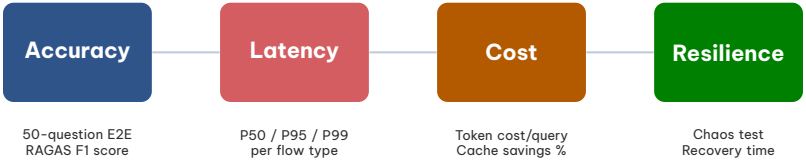
Canary, go-live và rollback



Tỷ lệ chỉ minh họa. So SLO, task success, tool error và cost với đủ số mẫu. Với Voice AI, tránh cắt cuộc gọi đang chạy khi đổi version.

R2. Phương án rollout, ngưỡng và xử lý phiên thoại cần được thiết kế / kiểm chứng riêng.

Holistic System Evaluation — 4 dimensions



Đo cost reduction **with vs without** semantic cache.
Typical: 30–60% token savings trên repeated queries.

Trace latency per component để identify bottleneck.
RAG retrieval thường chiếm 40–60% total latency.

Benchmark Report Template

Metric	Target	Actual	Status
RAGAS Faithfulness	≥ 0.80	—	☐
Answer Relevancy	≥ 0.80	—	☐
Latency P95	< 8s	—	☐
Token cost / query	$< \$0.05$	—	☐
Circuit breaker SLA	$\geq 99.5\%$	—	☐
Guardrail TP rate	$> 95\%$	—	☐
Cache hit rate	$> 40\%$	—	☐

Điền bảng này với số liệu thực từ hệ thống của bạn. Benchmark report = bằng chứng hệ thống hoạt động.

Đánh giá agent: outcome và độ ổn định

Outcome: kiểm tra trạng thái hệ thống đích. Câu trả lời "đã đặt lịch" cần đi kèm lịch hẹn thực sự tồn tại.

Trajectory: kiểm tra công cụ, tham số, quyền và các bước xác nhận. Cho phép nhiều đường đi hợp lệ đến cùng kết quả.

Bộ chấm: kết hợp kiểm tra bằng mã, rubric của model và người đánh giá. Hiệu chỉnh rubric bằng các trường hợp con người đã thống nhất.

Chỉ số	Ý nghĩa	Ví dụ giả định p = 0,8, k = 3
pass@k	Ít nhất một lần thành công	1 - (1 - 0,8)^3 = 99,2%
pass^k	Tất cả k lần đều thành công	0,8^3 = 51,2%

Ví dụ xác suất giả định các lần chạy độc lập và cùng p. Khi benchmark, báo số task, số trial và cách ước lượng.

N6. Giữ bộ kiểm tra hồi quy tách khỏi các bài đánh giá năng lực mới.

VINUNIVERSITY

04

Documentation Standards

Hệ thống không document thì không maintain được

3 loại documentation bắt buộc

ADRs

Why Reflexion not LATS?

Why DPO not RLHF?

Why PostgreSQL not MongoDB?

Future maintainers cần tradeoff context.

Runbook

Rotate API keys

Update knowledge base

Retrain LoRA adapter

Incident guide:

Circuit breaker tripped?

→ Step-by-step response

API Specs

OpenAPI spec

MCP tool schemas

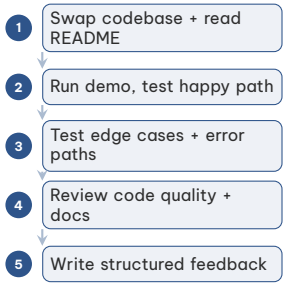
Example requests

Example responses

Consumers self-serve without asking dev team.

Lưu ý: System phải **maintainable bởi người không build nó**. Nếu chỉ bạn hiểu cách hệ thống hoạt động, đó là technical debt, không phải expertise.

Peer Review — Structured Feedback



Review format:

- **3 strengths**: cụ thể, có dẫn chứng
- **3 improvements**: actionable, có ví dụ
- **1 architecture question**: “Tại sao chọn X thay vì Y?”

Code quality & readability
Eval completeness (RAGAS scores)
Reliability (fallback, error handling)
Documentation (ADRs, runbook)

Ví dụ xử lý yêu cầu end-to-end

1. Nhận yêu cầu: người dùng hỏi thông tin hoặc đề nghị thay đổi một bản ghi. Hệ thống làm rõ mục tiêu và đối tượng.

2. Chuẩn bị dữ liệu: agent lấy nguồn phù hợp, kiểm tra quyền truy cập và tạo tham số có cấu trúc cho công cụ.

3. Kiểm soát hành động: policy gate xác định có cần xác minh / phê duyệt. Backend chỉ thực thi khi các điều kiện đã đủ.

4. Kiểm chứng kết quả: đọc trạng thái thực từ hệ thống đích, ghi audit và trả kết quả cho người dùng.

Khi có lỗi: giữ trạng thái đã hoàn thành, đối chiếu trước retry, chuyển người xử lý khi không thể khôi phục an toàn.

Kịch bản minh họa kiến trúc. Thử nghiệm lỗi cần kiểm chứng cả dữ liệu cuối cùng và lịch sử gọi công cụ.

N2, N3, N6. Luồng tổng hợp đề xuất.

Voice AI: turn-taking và ngắt lời

Khái niệm	Vai trò	Lỗi thường gặp
VAD	Phát hiện hoạt động tiếng nói	Ồn hoặc tiếng đệm gây kích hoạt sai
Endpointing	Chọn thời điểm đóng lượt nói	Cắt ngang ý hoặc chờ quá lâu
Turn detector	Ước lượng người dùng đã nói xong ý	Cần đánh giá ngôn ngữ và dữ liệu thực tế
Barge-in	Người dùng cắt lời agent đang nói	TTS dừng nhưng audio trong buffer vẫn phát

Khi ngắt lời: hủy phản hồi cũ, xóa audio chưa phát và đồng bộ lại phần hội thoại người dùng đã nghe.

Đo từ âm cuối của người dùng đến âm đầu phản hồi, gồm mạng và buffer. Tách TTFT của model khỏi độ trễ nghe được.

N8. Cách đo và xử lý buffer là khuyến nghị triển khai.

Voice AI: tải hệ thống và chi phí

Đại lượng	Ý nghĩa
CPS	Tốc độ khởi tạo cuộc gọi, khác số cuộc đang kết nối.
Trunk channels	Kênh thoại đang chiếm, có thể gồm thời gian đổ chuông.
AI CCU	Số phiên AI đang phục vụ, cần đo theo pipeline thực.
Call leg	Mỗi chặng kết nối có thời lượng và cước riêng.

Tổng chi phí: viễn thông + nền tảng media + ASR / LLM / TTS + lưu trữ + hạ tầng + người thật + thuế / phí.

Ví dụ block 60/60 giả định: một leg 90 giây tính 120 giây. 4.000 leg như vậy tạo 8.000 phút cước, dù thời lượng thực là 6.000 phút.

Xác nhận block và đơn vị tính từng dịch vụ trong hợp đồng. Đối soát CDR, usage AI và chi phí trên mỗi outcome.

N9 cho đối soát log / usage. Phân bổ chi phí và ví dụ block là minh họa.

VINUNIVERSITY

06

Chia sẻ dự án Voice AI

Inbound, outbound và trợ lý cuộc họp

Dự án 1: Voice Agent nhận cuộc gọi

Bài toán: hotline tiếp nhận nhiều yêu cầu lặp lại, có giờ cao điểm và cần chuyển nhân viên đúng bộ phận.

Luồng xử lý	Phương án
Tiếp nhận	Tổng đài nhận cuộc gọi, agent chào hỏi và xác định nhu cầu.
Xử lý	Xác minh theo rủi ro, tra cứu dữ liệu, xác nhận trước thao tác ghi.
Chuyển người	Bàn giao nội dung, mức xác minh và việc còn chờ. Có phương án khi queue bận.
Vận hành	Đo thời gian chờ, tỷ lệ giải quyết, chuyển tuyến và gọi lại.

Điểm cần giải quyết: audio một chiều, ngắt lời, tải đột biến, thời gian chờ và phiên thoại không được đóng.

Dự án minh họa chung. Không gắn khách hàng hay số liệu nghiệm thu cụ thể.

Dự án 2: Voice Agent gọi đi

Bài toán: nhắc lịch hoặc xác nhận thông tin theo danh sách, đồng thời kiểm soát gọi trùng và chi phí.

Luồng xử lý	Phương án
Trước khi gọi	Kiểm tra mục đích, điều kiện liên hệ, giờ gọi, từ chối liên hệ và lịch gọi lại.
Điều phối	Dialer giới hạn CPS, số kênh, AI CCU và năng lực chuyển nhân viên.
Hội thoại	Phân biệt người / voicemail, hỏi có tiện trao đổi, xác nhận thông tin quan trọng.
Hoàn tất	Ghi outcome, lý do thất bại, lịch hẹn và cước từng call leg.

Khi yêu cầu tạo cuộc gọi timeout, đối chiếu attempt đã gửi trước khi thử lại. Gọi lại mù dễ tạo cuộc gọi trùng.

Dự án minh họa chung. Quy tắc liên hệ cần được xác nhận theo mục đích và quy định áp dụng.

Dự án 3: Trợ lý cuộc họp

Bài toán: ghi nhận lời nói và tạo biên bản có thể đối chiếu, hỗ trợ theo dõi việc cần làm sau họp.

Luồng xử lý	Phương án
Ghi nhận	Thu audio, ASR streaming, gắn thời gian và phân biệt người nói.
Tổng hợp	Tách ý kiến, kết luận, nhiệm vụ và người phụ trách theo mẫu.
Đối chiếu	Liên kết tóm tắt với transcript / audio, đánh dấu trường chưa chắc.
Phát hành	Người dùng rà soát trước khi xuất biên bản hoặc tạo nhiệm vụ.

Điểm cần giải quyết: chất lượng thu âm, tên riêng, thuật ngữ, speaker và kết luận chưa được xác nhận.

Dự án minh họa chung. Nội dung và người nhận việc phải dựa trên bằng chứng của cuộc họp.

Nguồn kiến thức bổ sung

Mã	Tài liệu gốc	Liên kết
N1	**Context engineering** - Anthropic, 29/09/2025	Mở nguồn
N2	**Persistence / checkpointers** - LangGraph, tài liệu hiện hành	Mở nguồn
N3	**Interrupts và resume** - LangGraph, tài liệu hiện hành	Mở nguồn
N4	**Security Best Practices** - MCP, tài liệu hiện hành	Mở nguồn
N5	**Agent-to-agent và agent-to-tool** - A2A, tài liệu hiện hành	Mở nguồn
N6	**Demystifying evals for AI agents** - Anthropic, 09/01/2026	Mở nguồn
N7	**Harness design: long-running apps** - Anthropic, 24/03/2026	Mở nguồn
N8	**Turn-taking và interruptions** - LiveKit, tài liệu hiện hành	Mở nguồn
N9	**Call log và usage reconciliation** - Twilio, tài liệu hiện hành	Mở nguồn
R1	**Release engineering** - Google SRE	Mở nguồn
R2	**Canarying releases** - Google SRE	Mở nguồn
R3	**Phối hợp các team** - DORA	Mở nguồn

Nguồn đối chiếu 16/10/2026. Các ví dụ nghiệp vụ, tỷ lệ rollout và phân công team là mô hình minh họa.

Liên kết gắn mã tại các slide. Nguồn nền tảng 2025 được giữ cùng tài liệu cập nhật 2026.

Tổng kết

Kiến trúc: xác định ranh giới giữa agent, công cụ, workflow và hệ thống nghiệp vụ.

Khả năng phục hồi: quản lý context, checkpoint và chống lặp thao tác khi retry.

Release: phối hợp team theo tiêu chí chung, kiểm chứng trên staging và mở có kiểm soát.

Kiểm chứng: đánh giá outcome, độ ổn định, chất lượng và chi phí sau thay đổi.

Voice AI: đo trải nghiệm lượt nói cùng tải, cước viễn thông và kết quả xử lý thực tế.

Một thay đổi model, prompt, nguồn dữ liệu hoặc công cụ đều có thể làm thay đổi hành vi của toàn hệ thống.

Tổng hợp nội dung bài học và các nguồn N1–N9.

Hỏi & Đáp

Hệ thống production-ready thật sự cần gì — ngoài "code chạy được"?



Cảm ơn!

AICB-P2T3 · Ngày 28 · Workshop Tổng Hợp — Full Production Agent System

github.com/vinuni-aicb

Liên hệ: instructor@vinuni.edu.vn