VINUNIVERSITY

Triển Khai Thực Tế, Chi Phí Vận Hành & Định Hướng Chuyên Sâu

AICB-P1 · Ngày 15 · Ngày cuối Phase 1

Tên Giảng Viên

VinUniversity · Phase 1 · 2026

HÃY SUY NGHĨ...

“15 ngày trước bạn chưa biết LLM hoạt động thế nào. Hôm nay bạn đã có agent deployed, monitored, và evaluated. Câu hỏi bây giờ: đi sâu hướng nào?”

Giữ câu hỏi này trong đầu khi học bài hôm nay

Nội Dung Bài Học

1. 15 ngày nhìn lại
2. Triển khai enterprise
3. Cost anatomy
4. Cost optimization
5. Scaling production
6. Skills map recap
7. 3 Track Phase 2
8. Career paths & AMA

Mục Tiêu Ngày 15

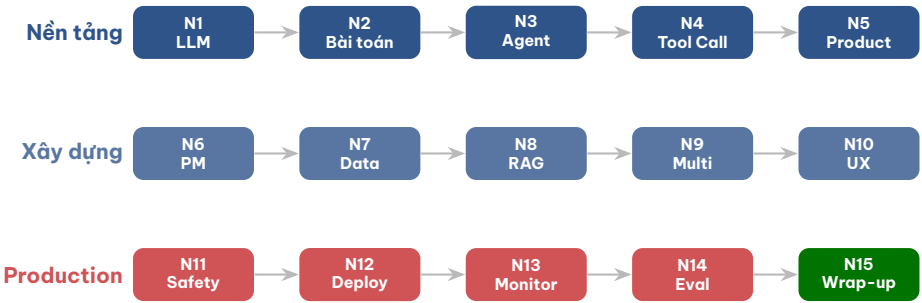
- Hiểu **thách thức triển khai enterprise**: security, compliance, legacy systems
- Phân tích **cost anatomy** của AI system và biết cách tối ưu chi phí
- Nắm **cost optimization strategies**: model routing, semantic caching, prompt compression
- Nhìn lại **skills map** đã tích luỹ qua 15 ngày
- Chọn **track Phase 2** phù hợp với mục tiêu nghề nghiệp

15 Ngày Nhìn Lại

01

Từ “AI là gì?” đến agent deployed, monitored, evaluated — một hành trình 15 ngày xây dựng năng lực thực chiến

Timeline: Hành Trình 15 Ngày



3 giai đoạn: **Hiểu nền tảng** (N1–5) → **Xây dựng hệ thống** (N6–10) → **Đưa lên production** (N11–15)

Milestones Đã Đạt Được

VINUNIVERSITY

Kỹ thuật

- Gọi LLM API, so sánh models
- Build ReAct agent + tool calling
- RAG pipeline grounded
- Multi-agent + MCP
- Guardrails + safety testing

Sản phẩm

- Problem statement + PRD
- UX với trust layer
- Deployed trên cloud
- Monitoring + alerting
- Evaluation + benchmark

Thông điệp

Bạn không chỉ học lý thuyết. Bạn đã **build, deploy, monitor, và evaluate** một AI product thật.

Triển Khai Enterprise

02

Lab deploy lên Railway là bước đầu. Enterprise có thêm security policies, compliance, legacy systems, và network restrictions

Enterprise Challenges

Security & Compliance

- Data không được rời khỏi VN
- PII phải encrypted at rest
- Audit trail cho mọi AI decision
- Compliance: PDPA, ngành tài chính

Technical Constraints

- Legacy systems, mainframe
- Network restrictions, air-gapped
- On-premise infrastructure only
- Limited GPU resources

Lưu ý: Enterprise deploy khác startup deploy. Không phải mọi thứ đều "push lên cloud" được. Đôi khi LLM phải chạy **on-premise**.

On-Premise vs Cloud vs Hybrid

	Cloud API	On-Premise	Hybrid
Data control	Thấp	Cao nhất	Tuỳ chọn
Setup time	Phút	Tuần–tháng	Tuần
Cost model	Per-token	Capex + GPU	Mixed
Performance	Nhanh	Tuỳ hardware	Tuỳ routing
Best for	MVP, startup	Bank, gov	Enterprise

Trend 2025–2026

Hybrid đang trở thành default cho enterprise VN: **sensitive data on-prem**, non-sensitive qua cloud API.

Self-Hosted LLM: vLLM & Ollama

VINUNIVERSITY

vLLM

Production-grade inference.

PagedAttention, continuous batching.

Dùng khi: cần throughput cao, có GPU server

Ollama

Run models locally, dễ setup.

Download model, chạy 1 lệnh.

Dùng khi: dev, demo, edge deployment

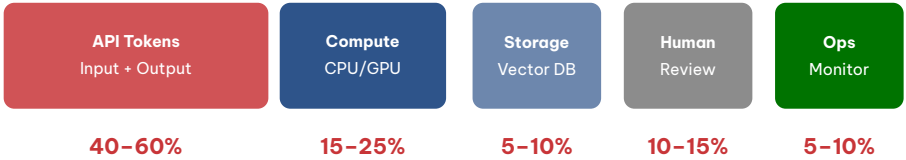
Lưu ý: Self-hosted tiết kiệm khi volume cao (> 1M tokens/ngày). Dưới mức đó, **cloud API rẻ hơn** khi tính cả chi phí GPU, ops, và maintenance.

03

Cost Anatomy Của AI System

AI agent production không chỉ tốn tiền token. Hiểu đầy đủ cost structure mới optimize đúng chỗ

Cost Breakdown



Insight

API tokens chiếm 40–60% cost. Optimize token usage là **ROI cao nhất** cho hầu hết AI systems.

LLM API Cost Calculator

VINUNIVERSITY

Công thức

Monthly cost =

(avg input tokens + avg output tokens)
× price per token
× requests per day
× 30 ngày

Ví dụ thực tế

1000 tokens/request
$3/1M input tokens (Sonnet)
500 requests/ngày

= 1000 × $0.000003 × 500 × 30
= **$45/tháng** chỉ LLM API

Lưu ý: Hidden costs thường gấp 1.5–2x API cost: retry overhead, guardrails LLM calls, monitoring, eval pipeline. Budget phải tính **tổng**, không chỉ API.

Budget Planning: 3-Tier Model

Tier	Traffic	Estimated cost	Stack
MVP	< 100 req/ngày	$50–200/tháng	Cloud API + Railway
Growth	100–5K req/ngày	$200–2K/tháng	Cloud API + ECS/Cloud Run
Scale	> 5K req/ngày	$2K+/tháng	Hybrid / self-hosted

Nguyên tắc

Bắt đầu MVP tier. Chỉ upgrade khi traffic thật sự đòi hỏi. **Premature optimization is the root of all evil.**

Cost Optimization Strategies

04

Khi cost bắt đầu đáng kể, 4 strategies sau giúp giảm 30–70% chi phí mà không ảnh hưởng chất lượng

4 Strategies Chính

1. Model Routing

Cheap model (Haiku) cho simple tasks.
Expensive model (Opus) chỉ cho complex.

Tiết kiệm: 40–60% token cost

2. Semantic Caching

Cache LLM responses cho similar queries.
Dùng embedding similarity để match.

Tiết kiệm: 20–40% nếu queries lặp

3. Prompt Compression

Tóm tắt context trước khi gửi LLM.
Giảm token count mà giữ thông tin.

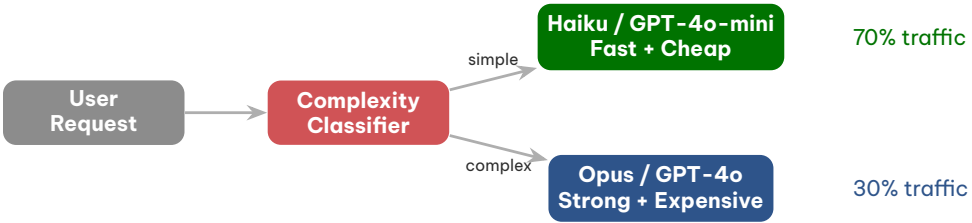
Tiết kiệm: 15–30% input tokens

4. Self-Hosted Models

vLLM, Ollama cho high-volume.
Break-even: khoảng 1M+ tokens/ngày.

Tiết kiệm: 50–80% so với API khi scale

Model Routing — Chi Tiết



Kết quả

Nếu 70% requests dùng cheap model (10x rẻ hơn), tổng cost giảm khoảng **50%** mà quality gần như không đổi trên simple tasks.

Scaling & Reliability Production

Khi agent phục vụ enterprise, cần thêm queue, circuit breaker, và SLA commitment

Production Patterns

Queue-Based Processing

High load → request queue → smooth out spikes.

User nhận "đang xử lý" thay vì timeout.

Tool: Redis Queue, Celery, Bull

Circuit Breaker

Khi LLM API down, degrade gracefully.

Trả cached response hoặc fallback message.

Pattern: closed → open → half-open

Horizontal Scaling

Stateless agent → N instances.

Day 12: đã design cho stateless.

Scale: thêm instances khi load tăng

SLA Considerations

Enterprise cần uptime commitment.

99.9% = max 8.7h downtime/năm.

Cần: redundancy, failover, monitoring

Skills Map Sau 15 Ngày

06

3 competency pillars đã được xây dựng — mỗi pillar mở ra một career direction khác nhau

Skills Map — 3 Pillars

CP3: AI Engineering

- LLM API
- ReAct Agent
- Prompt Engineering
- Tool Calling
- Embedding
- RAG Pipeline
- Multi-Agent
- Guardrails
- Evaluation

CP2: Infrastructure

- Vector Store
- Data Pipeline
- Docker
- Cloud Deploy
- Monitoring
- Structured Logging
- Tracing

CP1: Business

- Problem Statement
- AI Readiness
- PRD
- Risk Assessment
- ROI Analysis
- UX Design
- Cost Analysis

Sau 15 ngày: bạn đã có **deployed, monitored, evaluated AI product** + skills across 3 pillars.

07

Market Intelligence & Định Hướng Nghề Nghiệp Sâu

Trước khi chọn track Phase 2, hãy nhìn thị trường việc làm AI toàn cầu qua lăng kính của WEF, McKinsey, Stanford HAI, và chính các AI lab lớn nhất thế giới

Thị Trường Việc Làm AI Toàn Cầu Đến 2030

170M
Việc làm mới được tạo ra

92M
Việc làm bị mất đi

+78M
Tăng trưởng ròng (+7%)

Bức tranh lớn

86% nhà tuyển dụng kỳ vọng AI sẽ biến đổi doanh nghiệp của họ đến 2030. Nhưng **63%** coi khoảng cách kỹ năng là rào cản lớn nhất — cơ hội không tự động biến thành việc làm nếu thiếu kỹ năng đúng.

Nguồn: World Economic Forum, Future of Jobs Report 2025

Việt Nam Trong Bức Tranh Toàn Cầu

Chỉ số	Việt Nam	Toàn cầu
Tổ chức có chương trình AI đang chạy	**96%**	88%
Skills gap là rào cản chuyển đổi	**78%**	63%
Kế hoạch cắt giảm nhân sự vì AI	**58%**	41%
Kế hoạch reskilling để làm cùng AI	52%	**77%**
Cải thiện phát triển nhân tài nội bộ	≈**0%**	84%

Đọc vị: nhu cầu AI ở Việt Nam cao hơn thế giới, nhưng năng lực đào tạo lại nội bộ yếu hơn nhiều — vừa là cơ hội vừa là lời cảnh báo cho sinh viên được đào tạo bài bản.

Nguồn: World Economic Forum, Future of Jobs Report 2025 — Vietnam Country Profile

Nghịch Lý 2025–2026: Đầu Tư Tối Đa, Cắt Giảm Tối Đa

VINUNIVERSITY

Đầu tư kỷ lục

- Big Tech capex 2025: ~**$325 tỷ** (+46% YoY)
- Hướng dẫn 2026: **$725 tỷ** (+77%)
- Đầu tư AI doanh nghiệp toàn cầu: $252.3 tỷ (2024) → $581.7 tỷ (2025, +130%)

Nguồn: Stanford HAI AI Index 2025/2026; CNBC

Cắt giảm song song

- Amazon: cắt 14.000 + 16.000 vị trí (2025–2026)
- Meta: cắt 8.000 (10% nhân sự)
- Microsoft: 8.750 nghỉ hưu tự nguyện

"Chúng tôi sẽ cần ít người hơn cho một số công việc đang làm hôm nay."
— Andy Jassy, CEO Amazon

Nguồn: CNBC (2025–2026)

Tốc Độ Áp Dụng AI Đang Tăng Tốc

88%

Tổ chức dùng AI ở ít nhất 1 chức năng (McKinsey 2025)

72%

Dùng generative AI — tăng vọt từ 33% năm 2024

300%+

Tăng trưởng AI hiring toàn cầu trong 8 năm (LinkedIn)

20x

Số người thêm AI skill vào hồ sơ từ 2016 (LinkedIn)

Nguồn: McKinsey State of AI 2025; LinkedIn Work Change Report 2025

Nghề Nào Được Lợi, Nghề Nào Chịu Rủi Ro?

Các báo cáo lớn dùng nhiều khái niệm dễ nhầm lẫn. Hiểu đúng 3 khái niệm sau trước khi đọc số liệu.

Exposure (phơi nhiễm) — bao nhiêu % nhiệm vụ *có thể* được AI hỗ trợ/thực hiện — KHÔNG đồng nghĩa mất việc

Automation vs Augmentation — AI *thay thế* hoàn toàn nhiệm vụ, hay *hỗ trợ* con người làm tốt hơn

Net employment change — số liệu thực tế việc làm tăng/giảm — con số quan trọng nhất nhưng khó đo nhất

Nghề Tăng Trưởng: Được AI Khuếch Đại

VINUNIVERSITY

Top nghề tăng trưởng (WEF)

1. Big Data Specialists
2. FinTech Engineers
3. AI/ML Specialists
4. Software Developers
5. DevOps Engineers

Vì sao tăng trưởng

Wage premium kỹ năng AI: **56%** trung bình (PwC), có ngành tới 118%

Việc làm cần kỹ năng AI tăng nhanh gấp **8 lần** thị trường chung

Năng suất ngành phơi nhiễm AI cao: tăng gần **4 lần** (2018–2024)

Lưu ý

Việc làm vẫn tăng ngay cả ở nghề dễ tự động hoá nhất (PwC) — nỗi lo mất việc hàng loạt chưa xảy ra trên diện rộng.

Nguồn: World Economic Forum 2025; PwC Global AI Jobs Barometer 2025

Nghề Suy Giảm: Bị AI Thay Thế

Top nghề suy giảm (WEF)

1. Postal Service Clerks (−40%)
2. Bank Tellers (−35%)
3. Data Entry Clerks (−34%)
4. Cashiers/Ticket Clerks
5. Administrative Assistants

Mức độ phơi nhiễm

40% việc làm toàn cầu phơi nhiễm AI (IMF): 60% (nước phát triển), 40% (mới nổi), 26% (thu nhập thấp)

80% lực lượng lao động Mỹ có ≥10% nhiệm vụ bị ảnh hưởng (Eloundou et al., *Science* 2024)

Nghề phơi nhiễm cao nhất: **biên phiên dịch viên**

Lưu ý: Nghịch lý: nghề lương **cao** có xu hướng phơi nhiễm AI **cao hơn** nghề lương thấp — ngược với làn sóng tự động hoá/robot trước đây.

Klarna: Cắt Rồi Phải Tuyển Lại

Cắt từ 5.500 xuống 3.400 nhân sự, thay bằng chatbot AI (2024)

Sau đó: chất lượng dịch vụ giảm, khách hàng phàn nàn → **tuyển lại người**

"Luôn phải rõ ràng với khách hàng rằng sẽ luôn có một con người nếu bạn muốn."
— Sebastian Siemiatkowski, CEO Klarna

Nguồn: Fast Company; Entrepreneur (2025)

Lập Trình Viên Trẻ: Tác Động Đã Xảy Ra Thật

Việc làm lập trình viên 22–25 tuổi: **giảm ~20%** so với 2024

Tỷ lệ thất nghiệp SV mới ra trường CS: **6.1%** vs 4.3% trung bình Mỹ

"Tại sao thuê junior $90K khi GitHub Copilot chỉ tốn $10?"
— kỹ sư senior, khảo sát CIO.com

Nguồn: Stanford HAI AI Index 2026; CIO.com

Việt Nam: Ngành Nào Phơi Nhiễm AI Cao Nhất?

Ngành	Mức độ phơi nhiễm AI
Tài chính & Bảo hiểm	**82.6%**
Bán buôn & Bán lẻ	76.3%
Thông tin & Truyền thông	74.3%

Đọc vị: phơi nhiễm cao không đồng nghĩa mất việc — đây là ngành có nhiều nhiệm vụ *có thể* được AI hỗ trợ, cơ hội để tăng năng suất nếu biết dùng AI đúng cách, thay vì lo sợ bị thay thế.

Nguồn: IMF SDN/2024/001, phân tích theo ngành cho Việt Nam

Ngay cả những người tạo ra AI cũng đang tranh luận về tương lai việc làm. Đừng hoảng loạn theo một tuyên bố đơn lẻ — hãy nhìn toàn cảnh và tự quyết định.

4 câu hỏi sẽ giúp bạn chọn đúng track:

1. Chuyên gia AI nói gì — và họ có thực sự đồng thuận không?
2. Việc làm junior có thực sự bị đe doạ?
3. Kỹ năng nào vẫn bền vững dù AI phát triển đến đâu?
4. Track nào phù hợp với sở thích, khả năng, và mức độ chấp nhận rủi ro của bạn?

Ngay Cả Chuyên Gia Cũng Thay Đổi Quan Điểm

5/2025 — Cảnh báo mạnh

"AI có thể xoá sổ 50% việc làm văn phòng entry-level, thất nghiệp có thể lên 10–20%." — Dario Amodei, CEO Anthropic (Axios)

1/2026 — Giữ nguyên lập trường

Amodei tiếp tục cảnh báo trong essay *"The Adolescence of Technology"*; dự báo AGI có thể chỉ còn 1–2 năm

5/2026 — Đổi giọng cùng lúc với Altman

"Tự động hoá 90% công việc nghĩa là con người làm 10% còn lại nhưng năng suất tăng gấp 10 lần." — Amodei viện dẫn Jevons Paradox (Fortune). Cùng tuần, Sam Altman thừa nhận: *"trực giác của tôi đã sai"* về tác động entry-level (Time)

Nguồn: Axios 5/2025; darioamodei.com 1/2026; Fortune & Time 5/2026

Cuộc Tranh Luận: Có Nên Lo Về Việc Làm Junior?

Phe Cắt Giảm

"Chúng tôi sẽ không tuyển thêm kỹ sư phần mềm năm sau vì năng suất đã tăng hơn 30% nhờ AI."
— Marc Benioff, CEO Salesforce

22% CHRO xác nhận có lãnh đạo đã ngừng tuyển entry-level vì AI (Gartner)

Nguồn: Salesforce Ben; Gartner 2025–2026

Phe Phản Bác

"Ý tưởng AI thay thế lập trình viên junior là một trong những điều ngu ngốc nhất tôi từng nghe."
— Matt Garman, CEO AWS

IBM: tăng **gấp 3 lần** tuyển dụng entry-level tại Mỹ năm 2026

Nguồn: phát biểu công khai Matt Garman; IBM (Arvind Krishna), 2026

Kỹ Năng Bền Vững Trong Kỷ Nguyên AI

VINUNIVERSITY

Dữ liệu thực đo, không chỉ là quan điểm

Lao động 15+ năm kinh nghiệm đánh giá năng lực AI hiện tại **thấp hơn ~10 điểm %** so với lao động năm đầu — vì AI "thiếu phán đoán, nhận thức ngữ cảnh, và suy luận tình huống" (Anthropic Economic Index, 6/2026)

Khảo sát ngành nhân sự

Khi được hỏi kỹ năng con người nào quan trọng hơn khi AI đảm nhận nhiều việc hơn: **kiểm soát chất lượng đầu ra AI (50%)** và **tư duy phản biện (46%)** đứng đầu (Korn Ferry TA Trends 2026)

Andrew Ng

"Chỉ một phần nhỏ công việc của kỹ sư phần mềm là viết code." — kỹ năng còn giá trị: thu thập yêu cầu, thiết kế hệ thống, giao tiếp liên chức năng.

Nguồn: Ai4 2026 conference; Anthropic Economic Index; Korn Ferry

Ba Nhóm Nghề AI: Từ Nghiên Cứu Đến Sản Phẩm

Trước khi quyết định track, hãy nhìn cụ thể vào 3 nhóm nghề mà 3 track Phase 2 dẫn tới — mỗi nhóm có tốc độ tăng trưởng, mức lương, và rào cản gia nhập khác nhau.

AI Engineer

#1 fastest-growing job title (LinkedIn, 2 năm liên tiếp)

AI Infrastructure

Kỹ năng khó tuyển #1 toàn cầu (ManpowerGroup 2026)

AI Product

Tăng trưởng +300%/3 năm, nhưng thiếu cửa junior

AI Engineer / AI Researcher

VINUNIVERSITY

Demand & Lương

#1 fastest-growing job title 2 năm liên tiếp (LinkedIn)

ML Engineer trung vị: **$272.5K** (levels.fyi)

Frontier lab: OpenAI SWE $253K–$1.27M+

Case cực đoan: gói đãi ngộ researcher tới **$1.5 tỷ** (Meta, bị từ chối)

Rào Cản Gia Nhập

Research track: gần như bắt buộc PhD (OpenAI/DeepMind/FAIR)

Applied track: cử nhân/thạc sĩ + portfolio mạnh là đủ

PhD mới tại Mỹ/Canada tăng 22% (2022–2024) nhưng phần lớn vào academia, không phải industry

Nguồn: LinkedIn Jobs on the Rise 2025; levels.fyi; Stanford HAI AI Index 2025; TechCrunch

AI Infrastructure: Nhóm Khó Tuyển Nhất Thế Giới

VINUNIVERSITY

Demand & Lương

MLOps: tăng trưởng **9.8x trong 5 năm** (LinkedIn Emerging Jobs)

Senior/staff MLOps: $257K–$312K

Chi tiêu hạ tầng AI toàn cầu: $334 tỷ (2025) → $497 tỷ (2026) → **vượt $1.000 tỷ vào 2029** (IDC)

Khan Hiếm Nhân Sự

"AI Model & Application Development" là kỹ năng khó tìm #1 toàn cầu — vượt qua mọi ngành kỹ thuật truyền thống

20% nhà tuyển dụng toàn cầu xác nhận đây là kỹ năng khó tìm nhất

72% doanh nghiệp toàn cầu khó tuyển được nhân sự phù hợp

Nguồn: ManpowerGroup 2026 Global Talent Shortage Survey; IDC AI Infrastructure Spending; LinkedIn Emerging Jobs

AI Product: Tăng Trưởng Nhanh Nhưng Thiếu Cửa Junior

VINUNIVERSITY

Demand & Lương

- AI PM postings: **+300%** trong 3 năm, nhân đôi năm 2025
- Lương trung vị AI PM: $194–197K (hội tụ Glassdoor & axialsearch)
- AI Strategist: $208K trung vị, $279K ở cấp Director
- OpenAI PM trung vị: **~$860K**

Nguồn: axialsearch Labor Market Analysis 2026; Glassdoor; levels.fyi

Lưu ý: Chỉ **2%** postings AI PM là cấp junior — 47% là cấp Manager+. AI Strategist còn nghiêng hơn: 69–80% là Director/VP/C-suite. Thị trường "nóng nhưng chưa có lộ trình sự nghiệp rõ ràng cho người mới bắt đầu".

So Sánh Tổng Hợp: 3 Nhóm Nghề

Tiêu chí	Engineer/Researcher	Infrastructure	Product
Tăng trưởng	#1 fastest-growing title (2 năm)	9.8x/5 năm (MLOps)	+300%/3 năm
Lương trung vị	$272.5K (ML Engineer)	$257–312K (senior)	$194–208K
Rào cản gia nhập	PhD (research) / portfolio (applied)	2–3 năm kinh nghiệm liền kề	Portfolio sản phẩm, ít đòi bằng cấp sâu
Độ khó tuyển	Cao ở tier elite	**Khó nhất thế giới** (ManpowerGroup #1)	Thiếu cửa junior, không thiếu ứng viên

Nguồn: Tổng hợp LinkedIn, levels.fyi, ManpowerGroup, axialsearch (2025–2026)

Chọn Track: Framework Cá Nhân Hoá

Trục	Track 1 — Product	Track 2 — Infra	Track 3 — Application
Cơ hội thị trường	Tăng nhanh (+300%/3 năm), ít cửa junior	**Khó tuyển nhất thế giới** (ManpowerGroup)	#1 fastest-growing title 2 năm liên tiếp
Độ khó gia nhập	Thấp–trung bình: portfolio hơn bằng cấp	Trung bình–cao: cần nền tảng hệ thống	Cao (research) / trung bình (applied)
Phù hợp sở thích	Kinh doanh, chiến lược, giao tiếp đa bên	Hệ thống, vận hành, độ tin cậy quy mô lớn	Thuật toán, xây dựng sản phẩm kỹ thuật
Rủi ro AI tác động ngược	Thấp — vai trò phán đoán khó tự động hoá	Thấp — vẫn cần giám sát hạ tầng dài hạn	Trung bình ở phần code cơ bản (junior dev bị ảnh hưởng nhiều nhất)

Việt Nam 2030 — cơ hội cho chính bạn

Chiến lược AI Quốc gia đặt mục tiêu đào tạo **500.000 lao động** có kỹ năng AI, trong đó **50.000 chuyên gia trình độ cao** — đến 2030. Không có track "đúng tuyệt đối"; chọn theo giao điểm sở thích, năng lực, và mức độ sẵn sàng của chính bạn.

Nguồn: Vietnam National Strategy on AI to 2030; Digital Policy Alert

3 Track Giai Đoạn 2

Phase 1 cho nền tảng chung. Phase 2 đi sâu theo hướng bạn chọn — mỗi track 3 tuần chuyên sâu

Nội dung chính

- Product Strategy cho AI products
- Financial Modeling & ROI
- AI Governance & Compliance
- AI Act & regulatory landscape
- Go-to-market cho AI products

Phù hợp với ai

Người muốn làm:
AI Product Manager
AI Business Analyst
AI Strategist

Output

Business plan cho AI product + financial model + compliance checklist + go-to-market strategy.

Nội dung chính

- Lakehouse & Feature Store
- vLLM deployment & optimization
- CI/CD cho AI (LLMOps)
- GPU FinOps & cost management
- Production data pipeline

Phù hợp với ai

Người muốn làm:
AI Data Engineer
Platform Engineer
MLOps Engineer

Output

Production-grade data pipeline + self-hosted LLM + CI/CD pipeline + monitoring dashboard.

Nội dung chính

- Advanced Agent patterns
- Memory & long-term context
- GraphRAG & knowledge graphs
- Fine-tuning & model customization
- Production evaluation systems

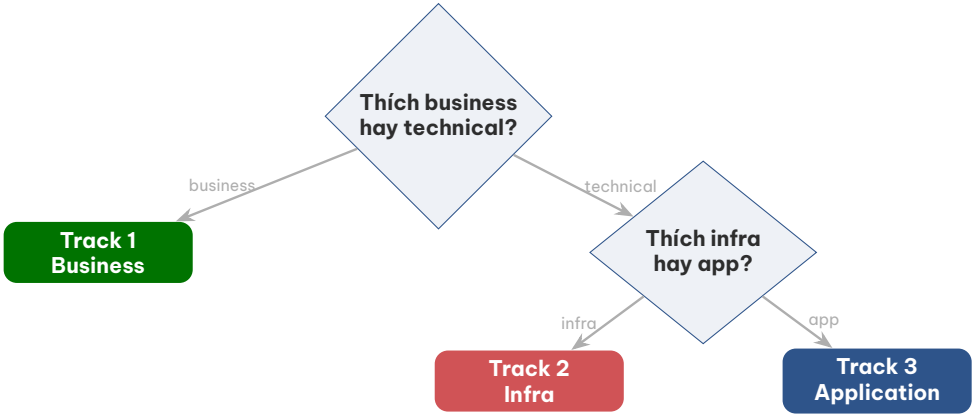
Phù hợp với ai

Người muốn làm:
AI Engineer
LLM Engineer
AI Agent Developer

Output

Advanced agent system + custom fine-tuned model + production eval pipeline + technical portfolio.

Chọn Track Như Thế Nào?



Lưu ý: Không có track "đúng" hay "sai". Chọn theo **mục tiêu nghề nghiệp** và **hứng thú cá nhân**. Có thể đổi track sau tuần đầu nếu cần.

Career Paths & Kết Thúc Phase 1

15 ngày, 15 labs, 1 deployed product. Bạn không còn là beginner — bạn là builder

09

Career Paths Sau Khoá Học

Pillar	Roles	Track	Demand
CP1	AI PM, AI BA, AI Strategist	Track 1	Cao, khan hiếm
CP2	AI Data Engineer, Platform Eng, MLOps	Track 2	Rất cao
CP3	AI Engineer, LLM Engineer, Agent Dev	Track 3	Cao nhất

VSF Internship

Từ portfolio khóa học → dự án thực tế tại Vingroup. **Portfolio mạnh = cánh cửa mở.**

Open Q&A Session

Mọi câu hỏi về kỹ thuật, career, track selection, hoặc bất kỳ điều gì bạn muốn hỏi.

Câu hỏi hay gặp nhất:

- "Track nào dễ xin việc hơn?" — *Cả 3 đều thiếu người. Chọn theo thế mạnh.*
- "Fine-tuning có cần không?" — *80% use cases không cần. RAG + prompt đủ.*
- "AI sẽ thay lập trình viên không?" — *AI thay code, không thay builder.*

Final Assignment

VINUNIVERSITY

Trước Ngày 16

1. Hoàn thành track selection form
2. Submit portfolio link (GitHub/demo URL)
3. Cost analysis cho agent (Lab 15)
4. Final presentation (10 phút)

Portfolio nên có

- Deployed agent URL
- Monitoring dashboard screenshot
- Evaluation report + RAGAS scores
- README giải thích architecture
- Cost analysis

Tổng kết — Key Takeaways

Những ý chính cần nhớ trước khi sang bài tiếp theo

1. **Enterprise deploy** khác startup: security, compliance, on-premise, hybrid. Hiểu context trước khi chọn architecture.

2. **Cost optimization:** model routing, semantic caching, prompt compression. API tokens chiếm 40–60% cost — optimize đúng chỗ.

3. **3 pillars, 3 tracks:** CP1 (Business) → Track 1, CP2 (Infra) → Track 2, CP3 (Application) → Track 3. Chọn theo mục tiêu.

4. **You are no longer beginners — you are builders.** 15 ngày, 15 labs, 1 deployed product. Phase 2 đi sâu hơn.

Tài Liệu Tham Khảo

1. Anthropic & OpenAI Pricing Docs — anthropic.com/pricing, platform.openai.com/tokenizer. Cost calculator.
2. vLLM Documentation — docs.vllm.ai. Self-hosted LLM inference, PagedAttention, quantization.
3. Strubell et al. (2019), *Energy and Policy Considerations for Deep Learning in NLP* — arXiv:1906.02243.
4. Market Intelligence (Section 7): WEF *Future of Jobs Report 2025*, McKinsey *State of AI 2025*, Stanford HAI *AI Index 2025/2026*, LinkedIn *Work Change Report*, IMF SDN/2024/001, PwC *AI Jobs Barometer 2025*, Goldman Sachs, Anthropic Economic Index, ManpowerGroup 2026, Gartner, IDC — danh mục đầy đủ tại `day15-career-market-research.md`.

Hỏi & Đáp

15 ngày từ zero đến deployed AI product. Phase 2 bắt đầu hành trình chuyên sâu của bạn.



Cảm ơn!

Tên Giảng Viên
Email: a.nguyen@vinuni.edu.vn
Tài liệu: github.com/vinuni/aicb-materials

Chúc mừng hoàn thành Phase 1!